


## Regresión Lineal Simple



### Preguntas de interés:

- ¿Existe relación entre  $X$  e  $Y$ ?
- ¿Cómo cambia  $Y$  en función de  $X$ ?
- ¿Qué valor <sup>de  $Y$</sup>  se puede esperar dado un valor de  $X$ ?


### Modelo

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad i = 1, \dots, n$$
$$\varepsilon_i \sim N(0, \sigma^2)$$


### Interpretación de los parámetros

$$\beta_0 : E(Y_i | X_i = 0) = \beta_0$$

$$\beta_1 : E(Y_i | X_i + 1) - E(Y_i | X_i) = \beta_1$$



Estimación de parámetros:  $\hat{\beta}_0, \hat{\beta}_1, \hat{\sigma}^2$



¿Cuál es la mejor recta, la que mejor representa la relación entre  $X$  e  $Y$ ?

Idea: Minimizar  $\sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - (\hat{\beta}_0 + \hat{\beta}_1 \cdot x_i))^2$

→ Método de mínimos cuadrados

→ Solución  $\leadsto$  Transpa 12

Ejemplo Bundesliga

-  $Y$ : Puntos

$$\bar{y} = 46,67, \quad s_y = 13,2$$

$X$ : Goles a favor

$$\bar{x} = 48,8, \quad s_x = 12,97$$

$$s_{xy} = 145,42 \leadsto r = 0,85$$

$$b_1 = \hat{\beta}_1 = \frac{s_{xy}}{s_x^2} = r \cdot \frac{s_y}{s_x}$$

$$b_0 = \hat{\beta}_0 = \bar{y} - b_1 \bar{x}$$

$$- \hat{\beta}_1 = 0,865, \quad \hat{\beta}_0 = 4,46$$

$$\hat{\beta}_1 = b_1 \sim N(\beta_1, \sigma_{b_1}^2)$$

$$\uparrow = \frac{\sigma^2}{(n-1) \cdot S_X^2}$$

$$\Leftrightarrow \frac{b_1 - \beta_1}{\sigma_{b_1}} \sim N(0, 1)$$

$$\Rightarrow \frac{b_1 - \beta_1}{S_{b_1}} \sim t_{n-2}$$

$$\uparrow = \sqrt{\frac{S^2}{(n-1) \cdot S_X^2}}$$

$$\leadsto IC(\beta_1; 1-\alpha) = b_1 \pm t_{n-2; 1-\alpha/2} \cdot S_{b_1}$$

$$= 0,865 \pm t_{376; 0,975} \cdot 0,028 = [0,81; 0,92]$$

↑

Ejemplo Bundesliga

$$\rightarrow n = 378$$

$$\rightarrow \alpha = 0,05$$

## Pruebas de hipótesis sobre $\beta_1$

- $H_0: \beta_1 = 0$  vs.  $H_1: \beta_1 \neq 0$

→ implica que  $X$  e  $Y$  son independientes

- $H_0: \beta_1 \leq 0,8$  vs.  $H_1: \beta_1 > 0,8$

## • Estadístico de contraste:

- $b_1 = \hat{\beta}_1 \sim N(\beta_1, \sigma_{b_1})$

- $H_0: \beta_1 = \beta_1^*$

$$\Rightarrow \frac{b_1 - \beta_1^*}{s_{b_1}} \underset{H_0}{\sim} t_{n-2}$$

## • Ejemplo (Bundesliga)


- $H_0: \beta_1 \leq 0,8$  vs.  $H_1: \beta_1 > 0,8$

- $\alpha = 0,05$ ;  $n = 378$

- $\hat{\beta}_1 = 0,865$ ,  $s_{b_1} = 0,028$


$$\Rightarrow t = 2,321$$

- valor crítico




$$t > 1,65 \Rightarrow \text{se rechaza } H_0$$

## Coefficiente de determinación ( $R^2$ )




$$b_1 \approx b_1^* \\ b_0 \approx b_0^*$$



→  $X$  "predice"  $Y$  bastante bien

→  $X^*$  es una variable entre varias que predicen  $Y^*$

¿Qué medida nos cuantifica el grado de asociación entre la variable respuesta y la(s) explicativa(s)?



• Variabilidad total de  $Y$ :

$$SQ_T = \sum_i (Y_i - \bar{Y})^2$$

• Variabilidad explicada por  $X$

$$SQ_E = \sum_i (\hat{Y}_i - \bar{Y})^2$$

• Variabilidad residual

$$SQ_R = \sum_i (Y_i - \hat{Y}_i)^2$$

$$SQ_T = SQ_E + SQ_R$$

$$R^2 = \frac{SQ_E}{SQ_T} = \frac{\sum (\hat{Y}_i - \bar{Y})^2}{(n-1) \cdot S_Y^2}$$

"Variabilidad de  $Y$  explicada por  $X$ ."

$$0 \leq R^2 \leq 1$$

$$\text{RLS: } R^2 = r_{xy}^2$$

$$R^2 = 1 \Leftrightarrow Y_i = \hat{Y}_i, \forall i$$

$$R^2 = 0 \Leftrightarrow \hat{Y}_i = \bar{Y}, \forall i \quad (= \text{recta con pendiente } 0)$$